

**Санкт-Петербургский государственный электротехнический
университет «ЛЭТИ» им. В.И. Ульянова (Ленина)**

Аналитическая обработка данных в задачах информационной безопасности

Санкт-Петербург
2026

Содержание

Глоссарий	4
1. Лекционный курс	6
1.1. Лекция 1: Основы ClickHouse	6
1.1.1. Определение	6
1.1.2. OLAP vs OLTP	6
1.1.3. Когда нужен ClickHouse	6
1.1.4. Взаимодействие с ClickHouse	6
1.1.5. Движки таблиц (Engines)	7
1.1.5.1. Основные группы движков	7
1.1.5.2. Семейство MergeTree	7
1.1.6. Merge — фоновый процесс объединения данных	7
1.1.7. Партиционирование	7
1.1.7.1. Типичные ошибки партиционирования	7
1.1.8. TTL — управление жизненным циклом данных	8
1.1.9. ORDER BY — физический порядок хранения	8
1.1.9.1. Проектирование ORDER BY	8
1.1.10. PRIMARY KEY	9
1.1.11. Проблема дублей и ReplacingMergeTree	9
1.1.11.1. Способы получить дедуплицированные данные	9
1.2. Лекция 2: RBAC и ABAC: модели управления доступом в ИБ	10
1.2.1. Зачем нужны модели управления доступом	10
1.2.2. RBAC: роль как единица администрирования	10
1.2.3. Иерархии ролей и разделение обязанностей	10
1.2.4. ABAC: политика на основе атрибутов	10
1.2.5. Как работает проверка доступа в ABAC	11
1.2.6. RBAC и ABAC: сравнение	11
1.2.7. Комбинированный подход RBAC + ABAC	11
1.2.8. Типичные ошибки проектирования доступа	11
1.3. Лекция 3: Распределённый ClickHouse: шарды, реплики и координация	12
1.3.1. Координация: ZooKeeper и ClickHouse Keeper	12
1.3.2. Шарды и реплики	12
1.3.3. Локальные и распределённые таблицы	12
1.3.4. Путь записи и чтения	12
1.3.5. Операционные риски распределённого кластера	13
1.3.6. Практические ориентиры проектирования	13
1.4. Лекция 4: Обезличивание персональных данных: модели и техники	14
1.4.1. Регуляторный контекст	14
1.4.2. Квази-идентификаторы	14
1.4.3. k-анонимность	14
1.4.4. Основные техники обезличивания	14
1.4.5. Обезличивание в OLAP-контексте	15
2. Лабораторный практикум	16
2.1. Введение в лабораторный практикум	16
2.2. Лабораторная работа 1: RBAC в ClickHouse	17
2.2.1. Цель	17
2.2.2. Подготовка	17
2.2.3. Часть 1: Роли и привилегии	17
2.2.3.1. Задание	17
2.2.3.2. Контрольные вопросы	18
2.2.4. Часть 2: Row Policies	18
2.2.4.1. Задание	18

2.2.4.2.	Контрольные вопросы	18
2.2.5.	Часть 3: Квоты и ограничения	18
2.2.5.1.	Задание	18
2.2.5.2.	Контрольные вопросы	18
2.2.6.	Часть 4: Проверка модели доступа	19
2.2.6.1.	Задание	19
2.2.6.2.	Вывод	19
2.3.	Лабораторная работа 2: Обезличивание персональных данных	20
2.3.1.	Цель	20
2.3.2.	Подготовка данных	20
2.3.3.	Вариант 1: Мутация (ALTER UPDATE)	21
2.3.3.1.	Задание	21
2.3.3.2.	Контрольные вопросы	21
2.3.3.3.	Когда уместно, когда нет	21
2.3.4.	Вариант 2: ReplacingMergeTree	21
2.3.4.1.	Задание	21
2.3.4.2.	Контрольные вопросы	22
2.3.4.3.	Когда уместно, когда нет	22
2.3.5.	Вариант 3: ETL-пайплайн	22
2.3.5.1.	Задание	22
2.3.5.2.	Контрольные вопросы	23
2.3.5.3.	Когда уместно, когда нет	23
2.3.6.	Проверка k-анонимности	23
2.3.6.1.	Задание	23
2.3.6.2.	Контрольные вопросы	24
2.3.7.	Итоговое сравнение	24
2.4.	Лабораторная работа 3: Аудит логов безопасности	25
2.4.1.	Цель	25
2.4.2.	Задание	25
2.4.2.1.	Часть 1: Схема данных	25
2.4.2.2.	Часть 2: Генерация событий	25
2.4.2.3.	Часть 3: Аналитические запросы	25
2.4.2.4.	Часть 4: Materialized Views для агрегации	25
2.4.2.5.	Связь с архитектурой ClickHouse	25
2.5.	Лабораторная работа 4: Private Set Intersection	26
2.5.1.	Цель	26
2.5.2.	Задание	26
2.5.2.1.	Часть 1: Подготовка данных	26
2.5.2.2.	Часть 2: Реализация PSI	26
2.5.2.3.	Часть 3: Верификация	26
2.5.2.4.	Связь с архитектурой ClickHouse	26

Глоссарий

Ad-hoc анализ — Разовые, незапланированные аналитические запросы для исследования данных или проверки гипотез. В отличие от регулярных отчётов, выполняются по требованию без предварительной настройки ETL-пайплайнов. Требуется интерактивной производительности и гибкого SQL.

API — Application Programming Interface — программная абстракция, определяющая методы и протоколы взаимодействия между программными компонентами. Обеспечивает унифицированный доступ к функциональности системы посредством стандартизированных вызовов, скрывая детали внутренней реализации.

BI — Business Intelligence — технологии и практики сбора, интеграции, анализа и представления бизнес-информации. Включает инструменты для создания отчётов, дашбордов, визуализации данных и поддержки принятия управленческих решений на основе данных.

CDN — Content Delivery Network — географически распределённая сеть серверов для кэширования и доставки статического контента пользователям с минимальной задержкой.

Компонент — Единица вычисления либо хранения данных, имеющая явно определённый контракт взаимодействия (интерфейс) и набор зависимостей.

CPU-time — Среднее процессорное время на транзакцию; оценивается через число ядер и TPS (мс на транзакцию).

CRM — Customer Relationship Management — система управления взаимоотношениями с клиентами. Программное обеспечение для автоматизации стратегий взаимодействия с клиентами, включая продажи, маркетинг, техподдержку и аналитику клиентских данных.

DAU — Daily Active Users — количество уникальных пользователей, взаимодействовавших с системой за сутки.

СУБД — Система управления базами данных — комплекс программных средств для создания, модификации и управления данными в базе данных. Обеспечивает структурированное хранение, эффективный доступ, целостность данных и управление конкурентным доступом.

DML — Data Manipulation Language — операции над данными в БД: SELECT/INSERT/UPDATE/DELETE.

downstream — В контексте конкретного вызова — вызываемая сторона (зависимость), которая обрабатывает запрос, полученный от upstream-сервиса.

Эмбединг — Векторное представление объекта (текста, изображения, пользователя, товара), полученное моделью машинного обучения для измерения семантической близости через расстояния в векторном пространстве.

Индекс — Вспомогательная структура данных в системах управления базами данных, предназначенная для оптимизации производительности операций поиска и извлечения информации. Организует упорядоченное представление данных для существенного сокращения времени доступа к записям.

Ввод-вывод — Input/Output — совокупность механизмов и протоколов обмена данными между вычислительной системой и внешними устройствами или другими системами. Включает операции получения данных из источников и передачи результатов обработки, представляя критически важный компонент архитектуры компьютерных систем.

IOPS — I/O Operations Per Second — количество операций ввода-вывода (чтения/записи) в секунду на уровне диска.

IoT — Internet of Things — сетевое взаимодействие физических устройств с датчиками и контроллерами. Характеризуется высокой частотой передачи небольших порций данных (телеметрия, метрики).

Слой — Множество компонентов, объединённых общей ответственностью и уровнем абстракции, и участвующих в системе согласно установленным правилам межслойных зависимостей. Говорят что слой А зависит от слоя Б если хотя бы один компонент слоя А зависит от компонента слоя Б.

LLM — Large Language Model — большая языковая модель на основе нейронных сетей, обученная на огромных объёмах текстовых данных. Способна генерировать код, текст, отвечать на вопросы и выполнять задачи программирования на основе естественно-языковых промптов.

LOC — Lines of Code — метрика объёма программного кода, измеряемая количеством строк. Используется для оценки размера кодовой базы, сложности проекта и трудозатрат на разработку. Не включает пустые

строки и комментарии при подсчёте физических строк (PLOC), либо учитывает только исполняемые инструкции при подсчёте логических строк (LLOC).

MAU — Monthly Active Users — количество уникальных пользователей за месяц.

Метаданные — Структурированная информация, описывающая свойства других данных: время создания, размер, тип, владелец, права доступа. Используется для индексирования и маршрутизации без чтения основного содержимого.

Морселизация — Техника параллельной обработки данных путём разбиения на небольшие фрагменты (morsels) фиксированного размера (обычно ~1024 строки). Каждый morsel обрабатывается независимо векторизованным движком, что обеспечивает эффективное использование CPU-кэшей и параллелизацию на уровне потоков.

OLAP — Online Analytical Processing — класс систем для аналитической обработки данных. Ориентирован на выполнение сложных агрегирующих запросов по большим объёмам данных, использует колоночное хранение для оптимизации производительности аналитики.

OLTP — Online Transaction Processing — класс систем обработки транзакций в реальном времени. Характеризуется большим количеством коротких транзакций (чтение, вставка, обновление, удаление), строковым хранением данных и требованиями к консистентности.

QPS — Queries Per Second — количество запросов к базе данных в секунду. Один HTTP-запрос может порождать несколько запросов к БД.

RPS — Requests Per Second — количество пользовательских запросов (например HTTP) в секунду.

Сессия — Логический контекст взаимодействия клиента с системой между множественными запросами. Хранит состояние пользователя: аутентификацию, корзину, настройки. Реализуется через cookies + серверное хранилище (Redis) или JWT-токены.

SLA — Service Level Agreement — соглашение об уровне обслуживания с количественными метриками: uptime (99.9% = 8.76 ч простоя/год), задержка ($p_{99} < 200$ мс).

Support — Служба поддержки и обработка обращений пользователей: тикеты, инциденты, запросы на возврат и консультации.

TPS — Transactions Per Second — количество транзакций БД в секунду.

Транзакция — Последовательность операций чтения и записи в базе данных, рассматриваемая как единая логическая единица работы. Гарантирует атомарность выполнения: либо все операции завершаются успешно и фиксируются (COMMIT), либо при ошибке все изменения откатываются (ROLLBACK).

upstream — В контексте конкретного вызова — вызывающая сторона (клиент), которая инициирует запрос к другому сервису и ожидает результат.

1. Лекционный курс

1.1. Лекция 1: Основы ClickHouse

Эта лекция формирует базовый понятийный аппарат курса: где находится место ClickHouse в архитектуре данных, как устроено хранение в MergeTree и почему в OLAP-системах критичны правильные ключи сортировки, партиционирование и фоновые merge-процессы.

1.1.1. Определение

ClickHouse — это распределённая СУБД с открытым исходным кодом, созданная для аналитической обработки запросов (OLAP) и хранения больших объёмов данных. Изначально разработана в Яндексе для Яндекс.Метрики — системы веб-аналитики, обрабатывающей миллиарды событий в сутки.

ClickHouse оптимизирован для сложных аналитических запросов, дашбордов и отчётности с низкой латентностью. Это позволяет аналитикам и инженерам строить интерактивные витрины и системы мониторинга поверх петабайтных объёмов данных, сохраняя высокую производительность даже при большом числе конкурентных запросов.

1.1.2. OLAP vs OLTP

	OLTP	OLAP
Назначение	Быстрые короткие транзакции: вставка, обновление, чтение отдельных записей	Сложные аналитические запросы: агрегация, группировка, анализ больших объёмов исторических данных
Оптимизация	Минимальная задержка, высокая согласованность при большом числе одновременных пользователей	Максимальная пропускная способность, высокая скорость сканирования миллионов/миллиардов записей
Схемы	Нормализованные, строгие ограничения, строковое хранение	Денормализованные (звезда, снежинка), колоночное хранение
Примеры	Платежи, заказы, CRM, банковские транзакции	BI, дашборды, Ad-hoc анализ запросы, мониторинг

Таблица 1. Сравнение OLTP и OLAP

1.1.3. Когда нужен ClickHouse

Подходит:

- Аналитика на больших объёмах данных (шардирование, горизонтальное масштабирование).
- Высокая скорость агрегирования.
- Интерактивные дашборды и мониторинг.
- Поточковая обработка — анализ данных в реальном времени.

Не подходит:

- Нужны полноценные транзакции (многотабличные ACID-транзакции, сложные BEGIN/COMMIT/ROLLBACK сценарии). Экспериментальная поддержка транзакций существует, но ограничена.
- Маленькие датасеты (для этого есть DuckDB).

1.1.4. Взаимодействие с ClickHouse

ClickHouse поддерживает несколько протоколов доступа:

- **Нативный TCP-протокол** — максимальная производительность, используется clickhouse-client и большинством драйверов.
- **HTTP / HTTPS интерфейс** — удобен для интеграции с веб-приложениями и мониторингом.
- **MySQL / PostgreSQL wire protocol** — совместимость с существующими клиентами и инструментами.
- **JDBC / ODBC драйверы** — для Java-приложений и BI-инструментов.

Вне зависимости от выбранного протокола, общение происходит на обычном SQL:

```
SELECT t1.id, t2.name
FROM t1
JOIN t2 ON t1.id = t2.id
```

1.1.5. Движки таблиц (Engines)

Поведение таблицы полностью определяется выбранным движком (engine). Именно engine определяет:

- как данные физически хранятся на диске,
- можно ли выполнять merge,
- поддерживается ли репликация,
- как работает дедупликация,
- возможны ли TTL и мутации (UPDATE/DELETE).

Выбор engine — это архитектурное решение. Его нельзя легко изменить без полной пересборки таблицы.

1.1.5.1. Основные группы движков

MergeTree-семейство — используется в большинстве продакшн-кейсов. Предназначено для больших объёмов аналитических данных.

Log / TinyLog — простые движки без merge и индексов. Используются для временных таблиц и тестирования.

Distributed — логический движок для работы с шардами. Сам данные не хранит.

Special engines — Kafka, Buffer, Dictionary — используются для интеграций и потоковой обработки.

1.1.5.2. Семейство MergeTree

- **MergeTree** — базовый вариант.
- **ReplicatedMergeTree** — с репликацией между нодами.
- **ReplacingMergeTree** — дедупликация по ключу при merge.
- **SummingMergeTree** — агрегация числовых колонок при merge.
- **AggregatingMergeTree** — хранение агрегатных состояний.
- **Collapsing / VersionedCollapsingMergeTree** — хранение событий с отменами.

1.1.6. Merge — фоновый процесс объединения данных

INSERT в ClickHouse никогда не переписывает существующие данные — он создаёт новые части (parts). Merge — это фоновый процесс, который объединяет эти части.

Это не оптимизация, а фундаментальная часть архитектуры. Система предполагает, что:

- данные пишутся быстро (append-only),
- порядок и консистентность достигаются позже (при merge),
- аналитика допускает небольшую задержку в «идеальности» данных.

1.1.7. Партиционирование

Партиции — это логическое разбиение таблицы на независимые части (обычно по дате), задаваемое выражением PARTITION BY.

Партиции позволяют:

- быстро удалять данные (DROP PARTITION — мгновенная операция),
- ограничивать scope merge,
- эффективно применять TTL,
- ускорять запросы с фильтрами по ключу партиционирования.

1.1.7.1. Типичные ошибки партиционирования

Основная ошибка — слишком мелкие партиции (например, партиционирование по user_id или uuid).

Количество партиций	Оценка
Десятки – сотни	Норма
1–2 тысячи	Допустимо в редких случаях
Десятки тысяч	Плохо
Сотни тысяч и более	Катастрофа

Таблица 2. Рекомендации по количеству партиций на таблицу

1.1.8. TTL — управление жизненным циклом данных

TTL — механизм автоматического удаления или перемещения данных по времени без внешних задач. Работает только в MergeTree-движках.

Важно: TTL не удаляет данные сразу, а дожидается merge. Данные будут существовать дольше указанного срока. При необходимости можно вручную запустить `OPTIMIZE TABLE ... FINAL`.

TTL работает на уровне частей (parts), а не партиций. Если TTL совпадает с границей партиций и включена настройка `ttl_only_drop_parts = 1`, ClickHouse целиком удаляет части, в которых все строки истекли — это быстрая операция. Без этой настройки (по умолчанию выключена) удаляются отдельные строки через мутации, что значительно дороже.

```
CREATE TABLE events_optimized (
    event_date Date,
    user_id UInt64,
    event_type String,
    data String
) ENGINE = MergeTree()
PARTITION BY toYYYYMM(event_date)
ORDER BY (event_date, user_id)
TTL event_date + INTERVAL 3 MONTH;
```

1.1.9. ORDER BY — физический порядок хранения

ORDER BY в определении таблицы определяет физический порядок хранения данных на диске. Это **не** порядок вывода в SELECT — для этого нужен отдельный ORDER BY в запросе.

Если поле из WHERE совпадает с префиксом ORDER BY, ClickHouse:

- читает минимальное количество данных,
- эффективно использует min/max индексы (sparse index),
- существенно уменьшает I/O.

1.1.9.1. Проектирование ORDER BY

ORDER BY должен:

- соответствовать самым частым фильтрам,
- **начинаться с колонок низкой кардинальности** (ascending cardinality),
- учитывать типичные паттерны запросов.

Это противоположно интуиции из OLTP (где B-tree индексы выигрывают от высокой селективности первой колонки). В ClickHouse sparse index работает иначе: первая колонка использует бинарный поиск, а для последующих колонок применяется generic exclusion search, который эффективен только когда предыдущая колонка имеет мало уникальных значений (одно значение покрывает много гранул). Кроме того, низкая кардинальность ведущей колонки значительно улучшает сжатие.

```
-- Хорошо: event_type (5-10 значений) первым, затем user_id (миллионы)
ORDER BY (event_type, user_id, event_date);
```

```
-- Плохо: user_id первым -- высокая кардинальность ломает
-- эффективность sparse index для последующих колонок
ORDER BY (user_id, event_type, event_date);
```


1.1.10. PRIMARY KEY

PRIMARY KEY определяет разреженный индекс и **ничего больше**.

Ключевые отличия от OLTP-систем:

- **ПК не гарантирует уникальность** — дубли разрешены.
- ПК обязан быть **префиксом** ORDER BY.
- Если PRIMARY KEY не указан — автоматически равен ORDER BY.

```
-- PRIMARY KEY автоматически = (timestamp, server_id, level)
ORDER BY (timestamp, server_id, level);
```

```
-- Можно указать более короткий ПК для экономии памяти:
ORDER BY (timestamp, server_id, level, request_id)
PRIMARY KEY (timestamp, server_id);
-- level и request_id участвуют в сортировке, но не в индексе
```

1.1.11. Проблема дублей и ReplacingMergeTree

Поскольку PRIMARY KEY не гарантирует уникальность, а UPSERT отсутствует, для управления дублями используется ReplacingMergeTree.

```
CREATE TABLE users_replacing (
    user_id UInt64,
    name String,
    email String,
    updated_at DateTime
) ENGINE = ReplacingMergeTree(updated_at)
PRIMARY KEY user_id;
```

При вставке строки с тем же ключом дубли **сохраняются**:

```
INSERT INTO users_replacing VALUES
(1, 'Alice', 'alice@example.com', '2026-01-01 10:00:00');
INSERT INTO users_replacing VALUES
(1, 'Alice Updated', 'new@example.com', '2026-01-01 11:00:00');
```

```
-- Дубли видны!
SELECT * FROM users_replacing WHERE user_id = 1;
-- -> 2 строки
```

1.1.11.1. Способы получить дедуплицированные данные

1. **FINAL** — дедупликация «на лету» при чтении:

```
SELECT * FROM users_replacing FINAL;
```

2. **argMax** — ручная дедупликация через агрегацию:

```
SELECT
    user_id,
    argMax(name, updated_at) AS name,
    argMax(email, updated_at) AS email,
    max(updated_at) AS updated_at
FROM users_replacing
GROUP BY user_id;
```

3. **OPTIMIZE TABLE ... FINAL** — принудительный merge:

```
OPTIMIZE TABLE users_replacing FINAL;
-- После этого дубли физически удалены
```

4. **Materialized View** — дедупликация при вставке в отдельную таблицу.

1.2. Лекция 2: RBAC и ABAC: модели управления доступом в ИБ

В этой лекции рассматриваются базовые модели авторизации как независимый слой архитектуры безопасности. Фокус — не на конкретной СУБД, а на том, как формально и операционно проектировать управление доступом в корпоративных системах.

1.2.1. Зачем нужны модели управления доступом

Аутентификация отвечает на вопрос «кто это?», а авторизация — «что этому субъекту разрешено делать?». Ошибки именно в авторизации часто приводят к критическим инцидентам: утечке данных, эскалации привилегий, нарушению принципа минимально необходимых прав.

Любая модель авторизации оперирует тремя базовыми сущностями:

- **Субъект** — кто запрашивает доступ: пользователь, сервис, процесс.
- **Объект** — к чему запрашивается доступ: таблица, файл, API-метод, запись.
- **Действие** — что именно субъект хочет сделать: чтение, запись, удаление, администрирование.

Модели отличаются тем, **как** они связывают субъекта с разрешёнными действиями над объектами. RBAC делает это через роли, ABAC — через атрибуты и контекст запроса.

1.2.2. RBAC: роль как единица администрирования

RBAC (Role-Based Access Control) строится на идее, что права назначаются не напрямую пользователям, а ролям. Пользователь получает права через принадлежность к роли.

Сущность RBAC	Назначение
Пользователь	Человеческий или машинный субъект, выполняющий действия
Роль	Функция в организации: аналитик, администратор, оператор
Привилегия	Разрешённая операция над объектом
Сеанс	Активированный поднабор ролей пользователя в рамках одного подключения. Пользователь может иметь несколько ролей, но в конкретной сессии работать только с частью из них — это ограничивает радиус возможного ущерба

Таблица 3. Базовые сущности RBAC

Преимущество RBAC — управляемость: при кадровых изменениях обычно достаточно изменить состав ролей, не пересобирая матрицу прав для каждого пользователя.

1.2.3. Иерархии ролей и разделение обязанностей

В зрелых системах роли образуют иерархию: старшая роль наследует права младшей. Это снижает дублирование политик и упрощает сопровождение.

Помимо иерархии, RBAC позволяет вводить ограничения на совмещение ролей. Классический пример: один сотрудник не должен иметь возможность и инициировать платёж, и самому же его утверждать — это открывает путь к мошенничеству без внешнего контроля. Такой принцип называется SoD (Separation of Duties, разделение обязанностей) и реализуется двумя способами:

- **Статическое SoD** — пользователь не может одновременно состоять в конфликтующих ролях. Система просто не позволит назначить обе роли одному человеку.
- **Динамическое SoD** — пользователь может иметь обе роли, но не может активировать их в рамках одной сессии или одной бизнес-операции.

1.2.4. ABAC: политика на основе атрибутов

RBAC отвечает на вопрос «к какой роли принадлежит пользователь?» и на основании этого разрешает или запрещает действие. Но иногда этого недостаточно: два аналитика имеют одинаковую роль, однако один работает из офиса, другой — из кафе за рубежом. Должны ли они иметь одинаковый доступ к чувствительным данным?

ABAC (Attribute-Based Access Control) решает эту задачу, добавляя к роли контекст запроса. Решение о доступе принимается на основе атрибутов:

- **Кто:** отдел, должность, уровень допуска.
- **Что:** тип данных, владелец ресурса, метка конфиденциальности.
- **Как:** чтение, запись, экспорт.
- **Когда и откуда:** рабочее время, корпоративная сеть, тип устройства.

Пример политики: «разрешить чтение отчётов отдела продаж, если сотрудник из того же отдела, подключается из офисной сети и сейчас рабочий день». Аналитик из другого отдела или тот же сотрудник из домашней сети — получают отказ, хотя роль у них одна и та же.

1.2.5. Как работает проверка доступа в ABAC

Когда пользователь обращается к ресурсу, система проходит четыре шага:

1. **Запрос перехватывается** в точке применения политики (PEP) — это может быть API-шлюз, прокси или middleware в приложении.
2. **Собираются атрибуты:** система запрашивает данные о пользователе из HR-системы, об устройстве — из MDM, о времени — из системных часов (PIP).
3. **Принимается решение:** движок политик (PDP) проверяет атрибуты против набора правил — тех самых, что администратор безопасности описал заранее — и выдаёт «разрешить» или «запретить».
4. **Решение применяется:** тот же PEP, что перехватил запрос, пропускает его или блокирует.

Такое разделение позволяет отдельно менять политики, отдельно — источники атрибутов, и при этом иметь полный аудитный след: почему конкретный запрос был разрешён или отклонён.

1.2.6. RBAC и ABAC: сравнение

Теперь, когда обе модели понятны, можно сравнить их по ключевым критериям.

Критерий	RBAC	ABAC
Основная единица	Роль	Атрибут + правило
Сложность внедрения	Ниже	Выше
Гибкость	Средняя	Высокая
Прозрачность для аудита	Высокая при корректной роли-модели	Зависит от качества политик и атрибутов
Типичный риск	Взрыв ролей: со временем ролей становится так много, что матрица прав теряет управляемость	Взрыв политик и рассогласованные атрибуты: правила множатся и начинают конфликтовать
Когда уместно	Стабильные бизнес-функции	Динамичный контекст доступа

Таблица 4. Сравнение RBAC и ABAC

1.2.7. Комбинированный подход RBAC + ABAC

На практике обе модели применяются вместе, потому что каждая закрывает слабость другой: RBAC прост и прозрачен, но не учитывает контекст; ABAC гибок, но сложен в администрировании.

Типичная гибридная схема: RBAC задаёт грубые границы полномочий, ABAC накладывает контекстные ограничения поверх роли. Например, роль «аналитик» даёт право читать витрины данных, а ABAC-политика уточняет: только своего домена, только из корпоративной сети, только в рабочее время.

1.2.8. Типичные ошибки проектирования доступа

- Назначение прав напрямую пользователям в обход ролевой модели — это ломает управляемость.
- Избыточные «универсальные» роли с административными правами вместо гранулярных.
- Отсутствие периодической ревизии: роли и атрибуты устаревают вместе с оргструктурой.
- Смешение бизнес-ролей (аналитик, менеджер) и технических ролей (read-only, admin) без явной границы.
- Отсутствие аудитного следа: если нельзя объяснить, почему запрос был разрешён, модель не считается зрелой.

1.3. Лекция 3: Распределённый ClickHouse: шарды, реплики и координация

Эта лекция фокусируется на том, как ClickHouse масштабируется за пределы одного узла. Цель — связать логические понятия кластера (шард, реплика, distributed-таблица) с практическими эффектами: пропускная способность, отказоустойчивость, сложность эксплуатации.

1.3.1. Координация: ZooKeeper и ClickHouse Keeper

ZooKeeper используется как координационная система в распределённых кластерах ClickHouse: репликация, распределённые DDL, синхронизация состояния. ZooKeeper — отдельный сервис на Java.

ClickHouse Keeper — более новая альтернатива, написанная на C++ и оптимизированная под ClickHouse. При прочих равных Keeper снижает операционную сложность кластера, поскольку использует единый технологический стек и лучше интегрирован с механизмами самой СУБД.

1.3.2. Шарды и реплики

ClickHouse для распределения данных использует два ключевых понятия.

Шард (shard) — часть общего набора данных. Каждый шард хранит собственный фрагмент таблицы. Например, при диапазонном разбиении логов за 12 месяцев:

- Шард 1: январь–апрель,
- Шард 2: май–август,
- Шард 3: сентябрь–декабрь.

Реплика (replica) — копия шарда для отказоустойчивости и балансировки чтения.

	Реплика 1	Реплика 2
Шард 1	Сервер A	Сервер B
Шард 2	Сервер C	Сервер D
Шард 3	Сервер E	Сервер F

Таблица 5. Пример топологии: 3 шарда x 2 реплики

Итоговое разделение ответственности:

- **Шарды** — горизонтальное масштабирование по данным и нагрузке.
- **Реплики** — отказоустойчивость и масштабирование чтения.

1.3.3. Локальные и распределённые таблицы

В кластере обычно используются два уровня таблиц.

1. **Локальные таблицы** (ReplicatedMergeTree) существуют на каждом узле и реально хранят данные:

```
CREATE TABLE events_local ON CLUSTER my_cluster (  
    id UInt64,  
    ts DateTime,  
    user_id UInt32  
) ENGINE = ReplicatedMergeTree(  
    '/clickhouse/tables/{shard}/events_local',  
    '{replica}'  
)  
PARTITION BY toYYYYMM(ts)  
ORDER BY (ts, user_id);
```

2. **Распределённая таблица** (Distributed) хранит только метаданные маршрутизации и проксирует запросы на локальные таблицы:

```
CREATE TABLE events_all ON CLUSTER my_cluster AS events_local  
ENGINE = Distributed(my_cluster, default, events_local, user_id);
```

1.3.4. Путь записи и чтения

При проектировании важно понимать, где именно выполняется операция:

- INSERT в локальную таблицу записывает данные сразу на конкретный шард.

- INSERT в Distributed-таблицу маршрутизирует строки по шару согласно sharding_key.
- SELECT из Distributed рассылает подзапросы по шардам, после чего инициатор агрегирует результат.

По этой причине стоимость запроса определяется не только сложностью SQL, но и сетевой топологией, равномерностью шардирования и объёмом межузловой передачи данных.

1.3.5. Операционные риски распределённого кластера

- **Skew данных** при неудачном sharding_key: часть шардов перегружена, часть простаивает.
- **Сетевые задержки** увеличивают latency распределённых агрегирующих запросов.
- **Долгие merge/мутации** на одной реплике могут вызывать рассогласование производительности между репликами.
- **Сложность DDL-изменений** возрастает: схемы и настройки должны применяться синхронно по всему кластеру.

1.3.6. Практические ориентиры проектирования

- Выбирать sharding_key, который распределяет данные равномерно и совпадает с основными паттернами запросов.
- Хранить «горячие» данные компактно, чтобы минимизировать межшардовые сканы.
- Использовать ON CLUSTER для схемной консистентности объектов.
- Планировать capacity с учётом не только объёма хранения, но и сетевого трафика между узлами.

С инженерной точки зрения распределённый ClickHouse — это баланс между скоростью аналитики, стоимостью инфраструктуры и управляемой сложностью эксплуатации.

1.4. Лекция 4: Обезличивание персональных данных: модели и техники

Эта лекция формирует теоретическую базу для лабораторной работы 2. Фокус — на формальных требованиях к обезличиванию, основных техниках трансформации данных и регуляторном контексте, определяющем, когда данные считаются действительно обезличенными.

1.4.1. Регуляторный контекст

Персональные данные (ПДн) — любая информация, позволяющая прямо или косвенно идентифицировать физическое лицо. Регуляторы разграничивают два понятия:

- **Псевдонимизация** — замена идентификаторов на псевдонимы; обратимая при наличии ключа или таблицы соответствия. Данные остаются персональными по GDPR / 152-ФЗ.
- **Анонимизация** — необратимое преобразование, после которого идентификация субъекта невозможна даже при наличии дополнительных источников. Только такие данные выходят из-под действия законодательства о ПДн.

На практике граница размыта: данные, кажущиеся анонимными, могут быть деанонимизированы через связку с внешними датасетами (**re-identification атака**).

1.4.2. Квази-идентификаторы

Прямые идентификаторы — поля, однозначно указывающие на человека: ФИО, email, СНИЛС, паспортные данные.

Квази-идентификаторы — поля, которые по отдельности безвредны, но в комбинации восстанавливают личность: дата рождения + пол + почтовый индекс. Исследования показывают, что такая тройка идентифицирует более 85% населения США.

Корректное обезличивание должно устранять угрозу реидентификации не только через прямые идентификаторы, но и через комбинации квази-идентификаторов.

1.4.3. k-анонимность

k-анонимность — формальная модель: каждая запись в датасете неотличима от не менее k–1 других записей по всем квази-идентификаторам. При k=1 каждая запись уникальна — полная уязвимость; при k=10 злоумышленник не может сузить пул кандидатов ниже 10 человек.

Достигается через:

- **Обобщение (generalization)** — замена точного значения диапазоном или категорией (возраст 27 → «20–29», город → регион).
- **Подавление (suppression)** — удаление строк или значений, нарушающих порог k.

k-анонимность не является достаточной гарантией, если чувствительный атрибут однороден внутри группы (атака по однородности). Более сильные модели (l-diversity, t-closeness) устраняют этот изъян, но для большинства практических задач курса k-анонимность достаточна.

1.4.4. Основные техники обезличивания

Техника	Описание	Обратимость
Маскирование	Замена символов: +7 921 ***-**-34	Нет (для замаскированных частей)
Хеширование	SHA-256 с солью; email → хеш	Нет (без соли/радужных таблиц)
Обобщение	Точное значение → диапазон/категория	Нет
Псевдонимизация	Замена на синтетический ID; ключ хранится отдельно	Да (с ключом)
Защумление	Добавление случайного сдвига к числовым полям	Нет

Таблица 6. Техники обезличивания и их свойства

Выбор техники зависит от цели: если данные нужны для аналитики (средний чек по возрастным группам), обобщение сохраняет статистическую ценность. Если данные используются как ключ в пайплайне (связка событий одного пользователя), подходит хеширование с солью.

1.4.5. Обезличивание в OLAP-контексте

В колоночных аналитических системах нет UPDATE в OLTP-смысле — мутации медленные и оставляют данные в неконсистентном состоянии во время выполнения. Это означает, что обезличивание в ClickHouse — это **ETL-задача**: чтение исходных данных, трансформация в отдельном пайплайне (в SQL внутри ClickHouse или внешним инструментом), запись в новую таблицу. Исходная таблица с ПДн после верификации удаляется.

Такой подход одновременно соответствует архитектурному паттерну (иммутабельность данных) и регуляторному требованию (возможность подтвердить факт уничтожения оригинальных ПДн).

2. Лабораторный практикум

2.1. Введение в лабораторный практикум

Практикум состоит из четырёх лабораторных работ на стыке аналитических баз данных и информационной безопасности. Лабораторные опираются на лекцию 1 (основы ClickHouse), лекцию 2 (модели управления доступом), лекцию 3 (распределённая архитектура ClickHouse) и лекцию 4 (обезличивание персональных данных).

Ключевая идея, проходящая через все лабораторные: ClickHouse — это колоночная аналитическая СУБД, а не OLTP-система. Каждая работа подсвечивает конкретное следствие этой архитектуры для задач ИБ:

- **Лабораторная 1 (RBAC):** роли, Row Policies, квоты; мутации тяжёлые, поэтому разграничение прав на ALTER критически важно.
- **Лабораторная 2 (обезличивание):** нельзя просто UPDATE ПДн, нужен ETL-пайплайн; студент сталкивается с ReplacingMergeTree и видит ограничения UPSERT-подхода для задач гарантированного уничтожения ПДн.
- **Лабораторная 3 (аудит):** append-only природа — **фича** для логов безопасности, удалить следы сложно.
- **Лабораторная 4 (PSI):** иммутабельность данных усиливает изоляцию между участниками протокола.

2.2. Лабораторная работа 1: RBAC в ClickHouse

2.2.1. Цель

Развернуть ClickHouse (Docker), создать таблицу с тестовыми данными, настроить ролевую модель доступа: пользователи, роли, привилегии, Row Policies, квоты. Убедиться, что разграничение прав в OLAP-системе работает иначе, чем в OLTP.

2.2.2. Подготовка

1. Развернуть ClickHouse через Docker Compose.
2. Подключиться к серверу через clickhouse-client.
3. Создать таблицу events и наполнить тестовыми данными:

```
CREATE TABLE events (  
    event_id UInt32,  
    timestamp DateTime,  
    user_id UInt32,  
    department String,  
    event_type String,  
    status String  
) ENGINE = MergeTree()  
PARTITION BY toYYYYMM(timestamp)  
ORDER BY (department, event_type, timestamp);  
  
INSERT INTO events  
SELECT  
    number,  
    now() - randUniform(0, 90*24*3600),  
    rand() % 1000,  
    ['sales','engineering','support'][rand() % 3 + 1],  
    ['login','logout','access','modify','delete']  
        [rand() % 5 + 1],  
    ['ok','error','denied'][rand() % 3 + 1]  
FROM numbers(50000);
```

2.2.3. Часть 1: Роли и привилегии

2.2.3.1. Задание

1. Создать три роли с разным уровнем доступа:

```
CREATE ROLE analyst;  
CREATE ROLE ingester;  
CREATE ROLE admin;  
  
-- analyst: только чтение  
GRANT SELECT ON default.events TO analyst;  
  
-- ingester: только вставка  
GRANT INSERT ON default.events TO ingester;  
  
-- admin: полный доступ (включая ALTER = мутации)  
GRANT ALL ON default.* TO admin;
```

2. Создать пользователей и назначить роли:

```
CREATE USER viewer IDENTIFIED BY 'viewer123'  
    DEFAULT ROLE analyst;  
CREATE USER loader IDENTIFIED BY 'loader123'  
    DEFAULT ROLE ingester;  
CREATE USER superuser IDENTIFIED BY 'admin123'  
    DEFAULT ROLE admin;
```

3. Проверить привилегии — подключиться как viewer:

```
clickhouse-client --user viewer --password viewer123
```

- `SELECT count() FROM events` — работает.
- `INSERT INTO events VALUES (...)` — ошибка `Not enough privileges`.
- `ALTER TABLE events DELETE WHERE 1` — ошибка `Not enough privileges`.

2.2.3.2. Контрольные вопросы

- Чем `GRANT ALL` отличается от перечисления `GRANT SELECT, INSERT, ALTER`?
- Что произойдёт, если пользователю назначены две роли с разными наборами прав?

2.2.4. Часть 2: Row Policies

2.2.4.1. Задание

1. Создать Row Policy — `viewer` видит только данные подразделения `sales`:

```
CREATE ROW POLICY sales_only ON events
  FOR SELECT USING department = 'sales'
  TO viewer;
```

2. Подключиться как `viewer` и выполнить:

```
SELECT department, count() FROM events GROUP BY department;
```

Результат: только строки `sales`. Остальные подразделения не видны.

3. Добавить вторую политику для другого пользователя:

```
CREATE USER eng_viewer IDENTIFIED BY 'eng123'
  DEFAULT ROLE analyst;
```

```
CREATE ROW POLICY eng_only ON events
  FOR SELECT USING department = 'engineering'
  TO eng_viewer;
```

4. Убедиться, что `eng_viewer` видит только `engineering`, а `viewer` — только `sales`.

2.2.4.2. Контрольные вопросы

- Чем Row Policy в ClickHouse отличается от `VIEW` с фильтром?
- Можно ли обойти Row Policy через подзапрос или `JOIN`?

2.2.5. Часть 3: Квоты и ограничения

2.2.5.1. Задание

1. Настроить квоту для роли `analyst`:

```
CREATE QUOTA analyst_quota_queries
  FOR INTERVAL 1 MINUTE MAX queries = 10
  TO analyst;
```

```
CREATE QUOTA analyst_quota_rows
  FOR INTERVAL 1 HOUR MAX result_rows = 100000
  TO analyst;
```

2. Подключиться как `viewer` и выполнить 11 запросов подряд — на 11-м получить ошибку `Quota exceeded`.
3. Настроить ограничение на уровне профиля:

```
CREATE SETTINGS PROFILE analyst_profile
  SETTINGS max_execution_time = 5,
           max_memory_usage = 100000000
  TO analyst;
```

4. Выполнить тяжёлый запрос от имени `viewer` и убедиться, что он прерывается по таймауту.

2.2.5.2. Контрольные вопросы

- Зачем нужны квоты в аналитической системе, если запросы только на чтение?
- Чем квоты отличаются от настроек профиля (`SETTINGS PROFILE`)?

2.2.6. Часть 4: Проверка модели доступа

2.2.6.1. Задание

1. Заполнить таблицу, подключаясь от имени каждого пользователя и проверяя каждую операцию:

Операция	viewer	loader	superuser
SELECT * FROM events	?	?	?
SELECT (видит все department?)	?	?	?
INSERT INTO events VALUES (...)	?	?	?
DROP TABLE events	?	?	?
11-й запрос за минуту (квота)	?	—	—

Таблица 7. Матрица доступа

1. Убедиться, что `system.query_log` фиксирует все действия всех пользователей, включая отклонённые запросы:

```
SELECT user, query, type, exception
FROM system.query_log
WHERE event_time > now() - INTERVAL 10 MINUTE
ORDER BY event_time DESC
LIMIT 20;
```

2.2.6.2. Вывод

RBAC в ClickHouse позволяет гранулярно разграничить доступ: от ролей и привилегий до фильтрации строк (Row Policies) и ограничения нагрузки (квоты). Все действия пользователей — включая отказы — аудируются через `system.query_log`.

2.3. Лабораторная работа 2: Обезличивание персональных данных

2.3.1. Цель

Разобрать три варианта обезличивания ПДн в ClickHouse средствами SQL: мутации, ReplacingMergeTree и ETL-пайплайн. Для каждого варианта — понять, в каких сценариях он уместен и где его применять нельзя. В финале — проверить результат обезличивания через метрику k-анонимности из лекции 4.

2.3.2. Подготовка данных

Данные генерируются один раз в таблицу-источник тремя батчами — по одному на каждый вариант обезличивания. Колонка batch используется как ключ партиционирования, что позволяет переместить каждый батч в отдельную таблицу одной командой MOVE PARTITION.

MOVE PARTITION — это операция на уровне метаданных файловой системы: данные физически не копируются, только переназначается владелец директории с партом. Поэтому она выполняется мгновенно независимо от объёма данных.

```
CREATE TABLE raw_source (  
    batch      UInt8,  
    user_id    UInt32,  
    full_name  String,  
    email      String,  
    phone      String,  
    birth_date Date,  
    city       String,  
    tx_amount  Float64,  
    version    UInt8  
) ENGINE = MergeTree()  
PARTITION BY batch  
ORDER BY user_id;  
  
-- Три идентичных батча, каждый попадёт в свой партишн.  
-- intHash32(number) даёт детерминированный хеш по номеру строки,  
-- поэтому данные одинаковы во всех трёх батчах.  
INSERT INTO raw_source  
SELECT  
    b                                AS batch,  
    number + 1                      AS user_id,  
    concat('User_', toString(number + 1)) AS full_name,  
    concat('user', toString(number + 1), '@example.com') AS email,  
    concat('+7', toString(9000000000 + intHash32(number) % 999999999)) AS phone,  
    toDate('1970-01-01') + toIntervalDay(intHash32(number + 1) % 18000) AS birth_date,  
    ['Москва', 'Санкт-Петербург', 'Балашиха', 'Гатчина', 'Подольск']  
        [intHash32(number + 2) % 5 + 1] AS city,  
    round(intHash32(number + 3) % 100000 / 100.0, 2) AS tx_amount,  
    1                                                AS version  
FROM numbers(10000)  
CROSS JOIN (SELECT arrayJoin([1, 2, 3]) AS b);  
  
-- Целевые таблицы --- одинаковая структура, разные движки  
CREATE TABLE users_mutation AS raw_source ENGINE = MergeTree()  
PARTITION BY batch ORDER BY user_id;  
  
CREATE TABLE users_rmt AS raw_source ENGINE = ReplacingMergeTree(version)  
PARTITION BY batch ORDER BY user_id;  
  
CREATE TABLE users_etl AS raw_source ENGINE = MergeTree()  
PARTITION BY batch ORDER BY user_id;  
  
-- Мгновенное перемещение партиций  
ALTER TABLE raw_source MOVE PARTITION 1 TO TABLE users_mutation;
```

```
ALTER TABLE raw_source MOVE PARTITION 2 TO TABLE users_rmt;
ALTER TABLE raw_source MOVE PARTITION 3 TO TABLE users_etl;
```

```
-- raw_source теперь пуст
SELECT count() FROM raw_source; -- 0
```

2.3.3. Вариант 1: Мутация (ALTER UPDATE)

Мутация — это механизм ClickHouse для изменения данных на месте. Подходит для разовых исправлений на небольших объёмах, когда допустима временная несогласованность и нет требований к немедленному подтверждению удаления.

2.3.3.1. Задание

- 1. Запустить обезличивание через мутацию:

```
ALTER TABLE users_mutation
  UPDATE email = hex(SHA256(concat('mysalt', email))),
         phone = concat('***', substring(phone, -4))
  WHERE 1
```

- 2. Убедиться, что мутация завершена и зафиксирована:

```
SELECT command, is_done
FROM system.mutations
WHERE table = 'users_mutation'
ORDER BY create_time DESC
LIMIT 5;
```

- 3. Выполнить SELECT email FROM users_mutation LIMIT 5 — данные уже изменены, вернуть оригинал невозможно.

2.3.3.2. Контрольные вопросы

- Что вернёт SELECT email FROM users_mutation LIMIT 5, запущенный прямо во время мутации на большой таблице? Допустимо ли такое поведение в продакшн-системе?
- Почему отсутствие отката — проблема именно для ПДн, но не для исправления технической ошибки в числовом поле?

2.3.3.3. Когда уместно, когда нет

Уместно	Не уместно
Разовое исправление ошибки в небольшой таблице	Большие таблицы: мутация блокирует merge и нагружает диск
Изменение технических полей (не ПДн)	Нужна атомарность или возможность отката
Обезличивание, когда допустима непоследовательность данных во время выполнения	Высокая нагрузка на запись: мутация конкурирует с фоновым merge

Таблица 8. Мутации: применимость

2.3.4. Вариант 2: ReplacingMergeTree

ReplacingMergeTree предназначен для UPSERT-паттерна: вставить строку с тем же ключом и более высоким version — и при merge старая версия исчезнет. Это основной способ обновления данных в ClickHouse без мутаций.

2.3.4.1. Задание

- 1. Вставить обезличенные строки в ту же таблицу users_rmt с version = 2 одним запросом:

```
INSERT INTO users_rmt
SELECT
  batch,
  user_id,
  '***' AS full_name,
  hex(SHA256(concat('mysalt', email))) AS email,
  concat('***', substring(phone, -4)) AS phone;
```

```

    birth_date,
    city,
    tx_amount,
    2
FROM users_rmt
WHERE version = 1;
AS version

```

2. Выполнить `SELECT count() FROM users_rmt` — таблица теперь содержит 20К строк: оригиналы и обезличенные копии.
3. Выполнить `SELECT email FROM users_rmt WHERE user_id = 1` — видны обе версии.
4. Выполнить `SELECT email FROM users_rmt FINAL WHERE user_id = 1` — видна только обезличенная.
5. Выполнить `OPTIMIZE TABLE users_rmt FINAL` — дождаться физического слияния.
6. После `OPTIMIZE` снова проверить `SELECT` без `FINAL` — дубли исчезли.

2.3.4.2. Контрольные вопросы

- Запустите `SELECT count() FROM users_rmt` до и после `OPTIMIZE FINAL`. Почему результаты отличаются и в какой момент ПДн физически исчезают с диска?
- Если вместо `OPTIMIZE FINAL` выполнить `ALTER TABLE users_rmt DELETE WHERE version = 1` — к какому из трёх вариантов это по смыслу ближе?

2.3.4.3. Когда уместно, когда нет

До `OPTIMIZE`: оригинальные ПДн физически лежат на диске рядом с обезличенными копиями. `FINAL` скрывает их при чтении, но не удаляет. `OPTIMIZE` — фоновая операция без гарантии времени завершения.

Уместно	Не уместно
Обновление операционных данных: изменение статуса, цены, флага	Обезличивание ПДн: нельзя подтвердить момент физического удаления
Дедупликация при параллельной вставке из нескольких источников	Требования 152-ФЗ/GDPR к гарантированному уничтожению данных

Таблица 9. ReplacingMergeTree: применимость

2.3.5. Вариант 3: ETL-пайплайн

2.3.5.1. Задание

1. Создать таблицу `anonymized_users` и наполнить её одним запросом:

```

CREATE TABLE anonymized_users (
    user_id    UInt32,
    age_group  String,
    region     String,
    email_hash String,
    tx_amount  Float64
) ENGINE = MergeTree()
ORDER BY user_id;
-- PARTITION BY не задан намеренно: колонка batch отсутствует
-- в обезличенной таблице, т.к. не несёт смысловой нагрузки.

INSERT INTO anonymized_users
SELECT
    user_id,
    concat(
        toString(intDiv(dateDiff('year', birth_date, today()), 10) * 10),
        '--',
        toString(intDiv(dateDiff('year', birth_date, today()), 10) * 10 + 9)
    )
    AS age_group,
    multiIf(
        city IN ('Москва', 'Балашиха', 'Подольск'),
        city IN ('Санкт-Петербург', 'Гатчина'),
        'Другой регион'
        'Московский регион',
        'Ленинградский регион',

```

```

    )
    hex(SHA256(concat('mysalt', email))) AS region,
    tx_amount AS email_hash,
FROM users_etl
WHERE version = 1;

```

Обратите внимание: в `anonymized_users` нет ФИО, телефона, точной даты рождения и города — только производные атрибуты.

2. После верификации удалить `users_etl` с оригинальными ПДн:

```
DROP TABLE users_etl;
```

Только после DROP факт уничтожения ПДн можно подтвердить — пока таблица существует, данные физически на диске.

3. Проверить сохранность аналитики:

```

-- Распределение по регионам
SELECT region, count() FROM anonymized_users GROUP BY region;

-- Средний чек по возрастным группам
SELECT age_group, avg(tx_amount) FROM anonymized_users GROUP BY age_group ORDER BY age_group;

-- Поиск по email невозможен без знания соли
SELECT * FROM anonymized_users WHERE email_hash = hex(SHA256(concat('wrongsalt',
'user@example.com')));

```

2.3.5.2. Контрольные вопросы

- Почему `DROP TABLE users_etl` даёт более однозначный момент уничтожения ПДн, чем завершённая мутация с `is_done = 1`?
- Субъект ПДн запросил удаление своих данных уже после того, как `users_etl` была удалена. Где ещё могут храниться его данные и что нужно проверить?

2.3.5.3. Когда уместно, когда нет

Уместно	Не уместно
Обезличивание ПДн с требованием подтверждения уничтожения	Частые обновления операционных данных — накладно держать две таблицы
Миграция и трансформация больших объёмов	Когда нужен live UPSERT без ETL-задержки
Нужна независимая аналитическая витрина поверх сырых данных	Схема источника часто меняется — поддержка трансформации становится дорогой

Таблица 10. ETL-пайплайн: применимость

2.3.6. Проверка k-анонимности

Обезличивание убрало прямые идентификаторы — ФИО, email, телефон. Но в таблице остались косвенные: возрастная группа и регион. Если какая-то комбинация этих двух полей встречается в таблице всего один раз — такую запись можно однозначно сопоставить с конкретным человеком, даже без имени.

k-анонимность — это измеримая гарантия: каждая комбинация квази-идентификаторов должна встречаться в датасете не менее k раз. При k=1 запись уникальна и уязвима; при k=5 злоумышленник не может сузить круг кандидатов меньше пяти человек.

Цель этого раздела — посчитать достигнутое k для `anonymized_users` и при необходимости поднять его до 5.

2.3.6.1. Задание

1. Посмотреть на распределение групп:

```

SELECT
    age_group,

```

```

    region,
    count() AS group_size
FROM anonymized_users
GROUP BY age_group, region
ORDER BY group_size ASC
LIMIT 20;

```

2. Найти минимальный размер группы — это и есть достигнутое k :

```

SELECT min(group_size) AS k_achieved
FROM (
    SELECT age_group, region, count() AS group_size
    FROM anonymized_users
    GROUP BY age_group, region
);

```

3. Если $k_achieved < 5$ — устранить уязвимые группы одним из способов:

- **Укрупнение бакетов:** пересоздать `anonymized_users` с более широкими диапазонами (например, «20–29» → «20–39») через `INSERT INTO ... SELECT` с изменённой формулой возраста.
- **Подавление:** удалить строки малых групп через `ALTER TABLE anonymized_users DELETE WHERE ...`. Это мутация, но здесь она безопасна — `anonymized_users` не содержит ПДн, только производные атрибуты.

4. Повторить проверку до достижения $k \geq 5$.

2.3.6.2. Контрольные вопросы

- По фактическому результату `SELECT age_group, region, count()` посчитайте число уникальных комбинаций квази-идентификаторов. Какой верхний теоретический предел для k в этом датасете? Совпал ли он с реальным результатом?
- Почему удаление строк через `ALTER DELETE` безопасно именно для `anonymized_users`, хотя мы выяснили, что мутации не дают быстрой гарантии уничтожения?

2.3.7. Итоговое сравнение

Критерий	Мутация	RMT	ETL
Скорость	Медленно на больших объёмах	Быстро	Зависит от объёма
Консистентность во время операции	Нет	Нет (до merge)	Да
Момент уничтожения ПДн	<code>is_done = 1 + old_parts_lifetime (8 мин)</code>	<code>OPTIMIZE FINAL + old_parts_lifetime;</code> сигнал — <code>system.merges</code>	<code>DROP TABLE</code> (атомарно)
Откат	Невозможен	Невозможен	Возможен до <code>DROP</code>
Типичный сценарий	Разовое исправление	Обновление операционных данных	Обезличивание, миграция

Таблица 11. Сравнение вариантов обезличивания

2.4. Лабораторная работа 3: Аудит логов безопасности

2.4.1. Цель

Построить мини-SIEM на базе ClickHouse: сбор, хранение и анализ security-событий. Append-only природа ClickHouse здесь работает **в пользу** безопасности.

2.4.2. Задание

2.4.2.1. Часть 1: Схема данных

1. Спроектировать таблицу `security_events` на движке MergeTree с партиционированием по дате (`toYYYYMM(timestamp)`).
2. Поля: `timestamp`, `event_type`, `source_ip`, `user_id`, `action`, `status`, `details`.
3. Выбрать ключ сортировки, оптимальный для типичных аналитических запросов (поиск по времени, по IP, по типу события).

2.4.2.2. Часть 2: Генерация событий

1. Написать Python-генератор, который создаёт поток security-событий:
 - Логины (успешные/неуспешные), в том числе серии brute-force.
 - Доступ к ресурсам (разрешённый/запрещённый).
 - Изменения привилегий.
2. Загрузить 100K событий за «3 месяца».

2.4.2.3. Часть 3: Аналитические запросы

1. Обнаружение brute-force: найти IP-адреса с более чем N неудачных попыток логина за 5 минут.
2. Аномальная активность: пользователи с нетипично большим количеством действий ($> 3\sigma$ от среднего).
3. Эскалация привилегий: цепочки событий «логин -> изменение роли -> доступ к ресурсу» за короткий промежуток.

2.4.2.4. Часть 4: Materialized Views для агрегации

1. Создать Materialized View `mv_failed_logins_per_minute`, который автоматически агрегирует неудачные логины по минутам и IP-адресам.
2. Сравнить производительность запроса к сырым данным и к Materialized View.

2.4.2.5. Связь с архитектурой ClickHouse

Append-only природа MergeTree означает, что злоумышленник не может легко удалить следы из логов: DELETE — это мутация, которая оставляет записи в `system.mutations` и `system.query_log`. Materialized View — это не кэш, а отдельная таблица, куда данные попадают при вставке; удаление из исходной таблицы не удаляет агрегаты.

2.5. Лабораторная работа 4: Private Set Intersection

2.5.1. Цель

Реализовать упрощённый протокол Private Set Intersection (PSI) на основе Diffie-Hellman: две «организации» находят общих клиентов, не раскрывая свои полные базы.

2.5.2. Задание

2.5.2.1. Часть 1: Подготовка данных

1. Создать две таблицы в ClickHouse: `org_a_clients` и `org_b_clients` с частичным пересечением по идентификатору (email).
2. Каждая таблица — обычный MergeTree, 100K записей.

2.5.2.2. Часть 2: Реализация PSI

1. Реализовать на Python протокол PSI на эллиптических кривых (или упрощённый DH):
 - Организация А хеширует свои email на кривую и отправляет точки организации В.
 - Организация В делает то же и вычисляет общий секрет.
 - Пересечение определяется по совпадению результатов.
2. Оркестрация: Python читает данные из ClickHouse, выполняет криптографические операции, записывает результат обратно.

2.5.2.3. Часть 3: Верификация

1. Проверить корректность: результат PSI должен совпадать с INNER JOIN по открытым данным.
2. Измерить overhead протокола по сравнению с прямым JOIN.

2.5.2.4. Связь с архитектурой ClickHouse

Данные в таблицах иммутабельны: организация В не может модифицировать данные организации А, даже имея доступ к ClickHouse. Row Policies (из лабораторной работы 1) дополнительно изолируют доступ. Результаты PSI записываются в отдельную таблицу — append-only, с полной аудируемостью (из лабораторной работы 3).